

Notas del Taller:
Realización de Modelos Lineales de Efectos Mixtos como alternativa para el análisis de datos

Gabriela E. López-Tolsa

Modelo con diseño de dos grupos

Paso 1: Preparar los datos.

Utiliza archivo de datos: “Data_15.csv”.

- a. Identificar nuestra variable dependiente (VD), en este caso la pausa post-reforzamiento (PPR); nuestra(s) variable(s) independiente(s) (VI), en este caso grupo; y los posibles efectos aleatorios, en este caso sujeto y sesión.
- b. Crear nuestra base de datos en Excel, en formato “largo”, es decir, utilizando una columna para cada variable/tipo de dato, por ejemplo:

	A	B	C	D	E	F	G
1	IF	Sesion	Grupo	Sujeto	PPR		
2	15	1 A		1	7.27213114		
3	15	1 A		3	5.43934426		
4	15	1 A		5	5.46557375		
5	15	1 A		7	5.49016391		
6	15	1 A		9	10.3967213		
7	15	1 A		11	9.88688527		
8	15	1 A		13	8.30983604		
9	15	1 A		15	5.37049182		
10	15	2 A		1	7.68032789		
11	15	2 A		3	5.79344258		
12	15	2 A		5	6.70000001		
13	15	2 A		7	5.06229508		
14	15	2 A		9	11.1		
15	15	2 A		11	9.68524591		
16	15	2 A		13	7.86065578		
17	15	2 A		15	5.71311477		
18	15	3 A		1	6.60655745		
19	15	3 A		3	6.01639342		
20	15	3 A		5	5.73114756		

Algunos puntos que considerar:

- Poner el título de la columna en la primera fila, sin espacios y, de preferencia, en el idioma en que pretendemos publicar los datos.
- Usar títulos sencillos y que correspondan con la forma en que se redactarían los resultados en el texto.
- Usar números sólo para variables cuantitativas, verificar que estén en la escala que queremos analizar (por ejemplo: proporción, tasa, porcentaje, segundos, etc.).
- Para variables cualitativas/categorías (como grupos y medidas repetidas) usar letras, considerando que se van a analizar por orden alfabético (ver columna “Grupo” que están acomodadas como A y B, en lugar de 1 y 2, o de Control y Experimental, etc.; hacer lo mismo con sesiones y con grupos). No es necesario que las letras sean consecutivas, sólo hay que tomar en cuenta que se analizan por orden alfabético (por ejemplo, S va a ir antes que W).

- En las variables de grupo la “primera” letra debe corresponder a lo que queremos como intercepto (generalmente nuestro grupo Experimental). Aquí el grupo “A” es el experimental y el grupo “B” es el control.
- No dejar espacios en blanco, por ejemplo, si un sujeto completó 10 sesiones, y otro 9, usar 10 filas para el primer sujeto, y 9 para el segundo sujeto.

→ Guardar el archivo con extensión “.csv”, ya que R lo maneja mejor que .xlsx.

Paso 2: Preparar script

*Algunos short-cuts:

Ctrl + 1: lleva al editor.

Ctrl + 2: lleva a la consola.

Ctrl + l: borra consola.

en el script para poner comentarios, es decir texto que no es parte del código.

Ctrl + enter: ejecuta línea seleccionada.

1. Crear un nuevo Script R (es el primer tipo de archivo).

2. Inicio del Script:

a. `rm(list=ls())`: “limpia” todo lo que haya en nuestro ambiente.

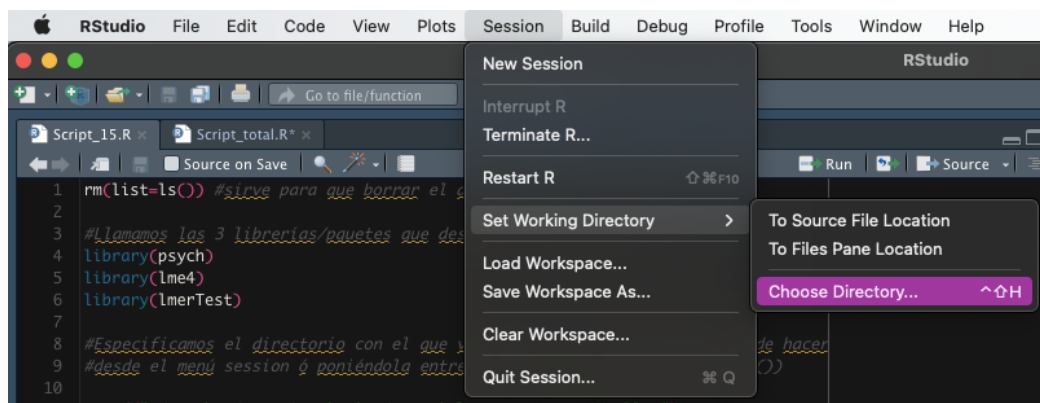
```
1 rm(list=ls())
```

b. Activar los paquetes que instalamos previamente usando “`library(paquete)`”

```
library(psych)
library(lme4)
library(lmerTest)
```

c. Poner nuestro directorio de trabajo (workdirectory).

- Sugiero ponerlo a través del menú Session...



- ...y luego copiar la línea de la consola...

```
Console Terminal × Markers × Jobs ×
~/Dropbox/aNew Statistics/Tutorial BLMM para AEC/Taller/ ➔
> setwd("~/Dropbox/aNew Statistics/Tutorial BLMM para AEC/Taller")
> |
```

- ... y pegarla en el script.

```
10
11 setwd("~/Dropbox/aNew Statistics/Tutorial BLMM para AEC/Taller")
12
```

d. convertir nuestro archivo de .csv a un objeto de r.

- Poner un nombre de objeto sencillo, sin espacios: ejemplo “datos”.
- Utilizar la función: `read.csv("Nombre_del_archivo.csv", na.string = "")` (na.string = "" deja en blanco los espacios en blanco que existan, en caso de que se nos pasara alguno).

```
16 datos <- read.csv("Data_15.csv")
17
```

El inicio del script quedaría así:

```
Script_15.R × Script_total.R* ×
← → Source on Save 🔍 🚀 📄 Ru
1 rm(list=ls()) #sirve para que borrar el ambiente
2
3 #Llamamos las 3 librerías/paquetes que descargamos anteriormente
4 library(psych)
5 library(lme4)
6 library(lmerTest)
7
8 #Especificamos el directorio con el que vamos a estar trabajando (se puede hacer
9 #desde el menú session ó poniéndola entre paréntesis con el comando setwd())
10
11 setwd("~/Dropbox/aNew Statistics/Tutorial BLMM para AEC/Taller")
12
13 #Creamos una variable para nuestros datos, recuerden usar nombres cortos, claros
14 #y sin espacios.
15
16 datos <- read.csv("Data_15.csv")
17
```


e. Vamos a correr esta primera parte, utilizando `ctrl + enter` para correr línea por línea (recomendable para que no se traben las computadoras).

Consideraciones:

- Asegurarse de que se cargan/activan todos los paquetes (en la consola), debe aparecer un signo de mayor que (“>”) al final.

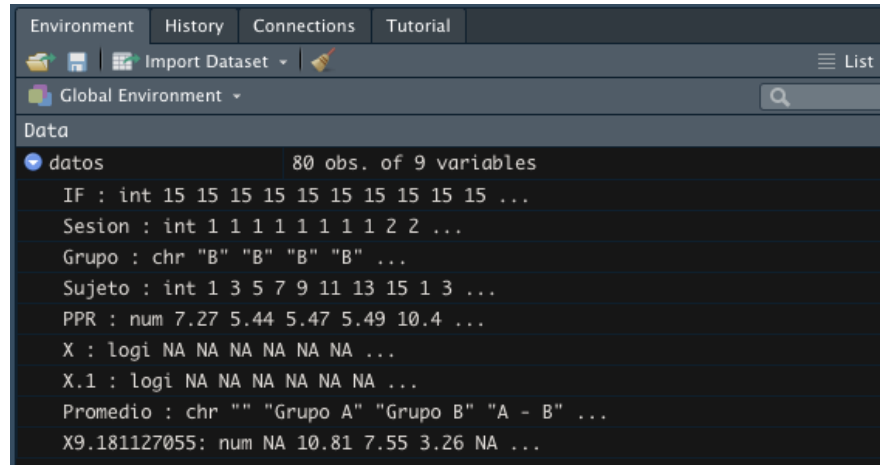
```
> library(lmerTest)
> |
```

- Verificar que se crea la tabla de “datos” (en el ambiente).



- Verificar que el contenido del objeto “datos” corresponda con nuestro archivo. Para ello tenemos dos opciones:

1. Dar click en la flechita/play:



2. o bien, doble click para abrirlo en el editor.

	IF	Sesion	Grupo	Sujeto	PPR	
1	15	1	B	1	7.272131	
2	15	1	B	3	5.439344	
3	15	1	B	5	5.465574	

3. Construcción de modelos

Vamos a empezar con la construcción de nuestros modelos, para ellos usaremos la función *lmer* de *lme4*. A esta función se le pueden agregar diferentes argumentos, pero los que usaremos aquí son “*formula*” y “*data*”. El argumento de *formula* lo pondremos de forma implícita, y el de *data* sí lo nombraremos. Los argumentos deben separarse por comas dentro de los paréntesis de la función.

a. Empezaremos creando el modelo “nulo”, que es el más sencillo, en el cual únicamente incluiremos la VD y nuestro efecto aleatorio.

- Se pone el nombre del modelo (usar algo muy sencillo como “m0”; utilizar números para diferenciarlos).
- La función “*lmer*” es la que va a calcular los resultados del modelo.
- Dentro del paréntesis ponemos primero nuestra VD, luego la virguita (~), y luego nuestro efecto aleatorio utilizando la nomenclatura que vimos en la presentación.
- Separando con coma, ponemos “*data* = NuestroObjetodeDatos”.

- En la siguiente línea poner “summary(NombreDelModelo)”, lo que nos permitirá ver el resumen del modelo después de correrlo.

```

33 m0 = lmer(PPR ~ (1|Sujeto),
34           data = datos)
35
36 #el primer argumento de lmer es la fórmula, que sería: "PPR ~ (1|Sujeto)"
37 #en este caso estamos diciendo que la PPR es función de los interceptos
38 #aleatorios para cada sujeto.
39 #el segundo argumento es "data", ponemos data=datos
40
41 summary(m0)

```

- b. Una vez creado el modelo nulo, ejecutamos el código, y “llamamos” el resumen dando ctrl + enter en la línea de *m0* y de *summary(m0)*. Vemos que en la consola aparecerá algo así:

```

Console Terminal x Markers x Jobs x
~/Dropbox/aNew Statistics/Tutorial BLMM para AEC/Taller/ Spellcheck
> m0 = lmer(PPR ~ (1|Sujeto),
+           data = datos)
> summary(m0)
Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
Formula: PPR ~ (1 | Sujeto)
Data: datos

REML criterion at convergence: 279.7

Scaled residuals:
    Min       1Q   Median       3Q      Max
-2.37954 -0.55452  0.00154  0.50718  2.77450

Random effects:
Groups   Name      Variance Std.Dev.
Sujeto   (Intercept) 6.7199   2.5923
Residual              0.9692   0.9845
Number of obs: 80, groups: Sujeto, 16

Fixed effects:
              Estimate Std. Error    df t value Pr(>|t|)
(Intercept)   9.1811     0.6573 15.0000  13.97 5.29e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
>

```

- Dado que no hemos usado nuestra(s) VI aún, el intercepto de efectos fijos debe ser parecido a la media de nuestra VD, lo verificamos en nuestro archivo de datos.

H1	A	B	C	D	E	F	G	H
1	IF	Sesion	Grupo	Sujeto	PPR		Prom total PPR:	9.18112705
2	15	1 B		1	7.27213114			
3	15	1 B		3	5.43934426			
4	15	1 B		5	5.46557375			

- De esta forma sabemos que el modelo está leyendo e interpretando los datos de forma correcta hasta aquí, así que podemos seguir con los modelos.

c. Ahora creamos un modelo un poco más complejo, en el que incluiremos nuestra VI (Grupo) y nuestro efecto aleatorio (sujetos, 1|Sujeto):

```
49 m1 = lmer (PPR ~ Grupo + (1|Sujeto),
50           data = datos)
51
52 #Volver a usar summary para ver los resultados del modelo, y lo comparamos con
53 #nuestro archivo de datos original para ver que tenga sentido lo que nos está
54 #saliendo y descartar errores de dedo/formato.
55
56 summary(m1)
```

- Volvemos a incluir la función de *summary* y ejecutamos tanto el modelo como el resumen, y de nuevo obtendremos esta información en la consola:

```
Console Terminal x Markers x Jobs x Spellcheck
~/Dropbox/aNew Statistics/Tutorial BLMM para AEC/Taller/ ↗
> m1 = lmer (PPR ~ Grupo + (1|Sujeto),
+           data = datos)
> summary(m1)
Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
Formula: PPR ~ Grupo + (1 | Sujeto)
Data: datos

REML criterion at convergence: 269.9

Scaled residuals:
    Min       1Q   Median       3Q      Max
-2.37921 -0.55764  0.01209  0.48597  2.79789

Random effects:
 Groups   Name      Variance Std.Dev.
 Sujeto   (Intercept) 4.1735   2.0429
 Residual              0.9692   0.9845
Number of obs: 80, groups: Sujeto, 16

Fixed effects:
              Estimate Std. Error    df t value Pr(>|t|)
(Intercept)  10.8121    0.7389 14.0000  14.634 7.06e-10 ***
GrupoB       -3.2620    1.0449 14.0000  -3.122  0.0075 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Correlation of Fixed Effects:
      (Intr)
GrupoB -0.707
> |
```


d. Una vez que corrimos el modelo, vamos a verificar los datos que nos da con nuestro archivo de datos. Particularmente veremos el intercepto y la pendiente.

Nótese que la pendiente se llama “GrupoB” ya que se refiere al cambio del grupo A al **grupo B**.

H4 $f_x = H2-H3$								
	A	B	C	D	E	F	G	H
1	IF	Sesion	Grupo	Sujeto	PPR		Prom total PPR:	9.18112705
2	15	1 B		1	7.27213114		Prom Grupo A:	10.8121312
3	15	1 B		3	5.43934426		Prom Grupo B:	7.55012295
4	15	1 B		5	5.46557375		Diferencia A - B:	3.26200821
5	15	1 B		7	5.49016391			

Observamos que el promedio del grupo A es muy parecido (idéntico, en este caso), y que la diferencia de $A - B$ es muy parecida (idéntica también) a la pendiente.

La pendiente es negativa porque el promedio de B es menor que el de A, por lo tanto, si conectamos ambos puntos la pendiente se verá así:



e. Seguimos construyendo modelos con base en los datos que tenemos. En este caso añadiremos también un efecto aleatorio de la sesión.

```
57  
58 m2 = lmer(PPR ~ Grupo + (1|Sujeto) + (1|Sesion), data = datos)  
59  
60 summary(m2)  
61
```

Ejecutamos nuestro código de la misma forma que con los modelos anteriores. Y observaremos que, en ese caso, tanto el intercepto como la pendiente son iguales para ambos modelos.

f. Recordemos que uno de los beneficios de usar Modelos Lineales Mixtos es que podemos aproximarnos a los datos con el enfoque de “mejor modelo”, por lo que ahora vamos a utilizar la función *anova* para hacer una prueba de razón de verosimilitud que nos indique cuál de nuestros modelos es el que mejor se ajusta a nuestros datos, es decir, cuál es el que mejor los describiría.

Ponemos la función *anova*, y entre paréntesis incluiremos los modelos que hayamos hecho separados por comas.

```
62 #Una vez que tenemos todos los modelos que consideremos pertinentes, utilizamos  
63 #la función de "anova" para determinar cuál es el mejor.  
64  
65 anova(m0,m1,m2)  
66
```

Los resultados de la prueba de razón de verosimilitud nos indican que el mejor modelo en este caso es m1, como lo indican los asteriscos. En este caso, m1 es mejor modelo que m2 dado que con menos argumentos produce los mismos resultados.

```

> anova(m0,m1,m2)
refitting model(s) with ML (instead of REML)
Data: datos
Models:
m0: PPR ~ (1 | Sujeto)
m1: PPR ~ Grupo + (1 | Sujeto)
m2: PPR ~ Grupo + (1 | Sujeto) + (1 | Sesión)
      npar    AIC    BIC logLik deviance Chisq Df Pr(>Chisq)
m0      3 286.68 293.83 -140.34  280.68
m1      4 280.23 289.75 -136.11  272.23 8.4535  1  0.003643 **
m2      5 282.02 293.93 -136.01  272.02 0.2061  1  0.649839
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> |

```

Paso 3: Análisis e interpretación del modelo.

1. Ver el mejor modelo usando la función *summary()*

a. Primero nos centramos en los efectos fijos:

- Identificamos los estimados del intercepto y las pendientes, así como sus errores estándar.
- Si queremos agregar algún tipo de “test de significancia” adicional, usamos el valor *t* y la *p* obtenida (última columna). Esto no es el objetivo de usar este tipo de modelos, pero dado que el enfoque de “mejor modelo” aún no es muy popular, estos valores de significancia ofrecen un punto medio.
- La significancia del intercepto sólo nos va a decir si es diferente de 0, por lo que no suele ser relevante.
- La significancia de las pendientes sí puede reportarse.

```

> summary(m1)
Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
Formula: PPR ~ Grupo + (1 | Sujeto)
Data: datos

REML criterion at convergence: 269.9

Scaled residuals:
    Min       1Q   Median       3Q      Max
-2.37921 -0.55764  0.01209  0.48597  2.79789

Random effects:
 Groups   Name      Variance Std.Dev.
 Sujeto   (Intercept) 4.1735   2.0429
 Residual                0.9692   0.9845
Number of obs: 80, groups: Sujeto, 16

Fixed effects:
              Estimate Std. Error    df t value Pr(>|t|)
(Intercept)  10.8121    0.7389 14.0000  14.634 7.06e-10 ***
GrupoB       -3.2620    1.0449 14.0000  -3.122  0.0075 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Correlation of Fixed Effects:
      (Intr)
GrupoB -0.707
> |

```


- Para obtener más información también podemos consultar los coeficientes del modelo con la función *coef()*, que, en este caso, por ser un modelo sencillo, únicamente nos indicarán el intercepto para cada sujeto:

```

Console Terminal x Markers x Jobs x
~/Dropbox/aNew Statistics/Tutorial BLMM para AEC/

> coef(m1)
$Sujeto
  (Intercept)  GrupoB
1    10.395458 -3.262008
2    11.519288 -3.262008
3     9.678902 -3.262008
4    12.973706 -3.262008
5     9.417282 -3.262008
6     8.934735 -3.262008
7     9.484645 -3.262008
8    14.094442 -3.262008
9    13.766751 -3.262008
10    9.767845 -3.262008
11   13.092180 -3.262008
12   12.245557 -3.262008
13   11.365488 -3.262008
14    7.910187 -3.262008
15    9.296342 -3.262008
16    9.051289 -3.262008

attr(,"class")
[1] "coef.mer"
> |

```

Paso 4: Redactar análisis de datos y resultados.

- Ahora veremos un ejemplo de cómo redactar tanto el análisis de datos, como la sección de resultados.
- Es importante que citemos tanto el software como los paquetes que utilicemos, ya que son gratuitos para nosotros, pero representan una inversión de tiempo y esfuerzo de los desarrolladores.
- También a mí me gusta hacer una muy breve introducción/justificación sobre por qué usamos modelos lineales mixtos.
- También es una buena práctica utilizar algún repositorio para poner disponibles nuestros datos y códigos; por ejemplo, yo uso github.

1. Ejemplo de redacción de sección de análisis de datos: (importante citar el software y los paquetes, sobretodo porque son de acceso libre).

“El uso de Modelos Lineales de Efectos Mixtos ha ido incrementando en psicología y otras ciencias de la conducta, ya que presenta varias ventajas sobre otros métodos estadísticos, como que toman en cuenta la varianza intra- y entre-sujetos, lidian bien con datos desbalanceados y/o anidados y nos indican la dirección y magnitud del efecto (Boisgontier & Cheval, 2016; Brown, 2021; Harrison et al., 2018; Young, 2018; Winter, 2013). Se utilizaron Modelos Lineales Mixtos para evaluar las diferencias en la pausa post-reforzamiento (PPR) de los grupos A y B. Primero se construyó un modelo nulo, y luego se usó una prueba de razón de verosimilitud para determinar cuál es el modelo que mejor se ajustaba a los datos. El modelo que mejor se ajustaba a los datos será descrito en la sección de resultados. Todos los análisis de efectos mixtos se llevaron a cabo usando los paquetes lme4 (Bates, Mächler, Bolker & Walker, 2015) y lmerTest (Kuznetsova, Brockhoff & Christensen, 2017) en R (R

Team, 2012), usando el ambiente Rstudio (Rstudio Team, 2020). Los códigos utilizados y bases de datos se pueden encontrar en github.com/ejemplo/cienciaabierta.”

*Para saber cómo citar los paquetes y software basta con hacer una búsqueda rápida en internet tipo: “cite lme4”.

2. Ejemplo de redacción de sección de resultados.

- En los resultados es importante incluir una breve descripción de los componentes del modelo, así como su fórmula. Si tenemos varios análisis puede ser más cómodo poner una tabla con las diferentes fórmulas.
- Después ponemos de qué fue función nuestra VD, con base en el mejor modelo, y añadimos el resultado de la prueba de razón de verosimilitud.
- Por último, agregamos la(s) pendiente(s), indicando su dirección y tamaño, así como la prueba estadística si así lo decidimos.

“El Modelo Lineal Mixto usado en el Experimento 1 incluyó al grupo (A vs. B) como efecto fijo e interceptos aleatorios por sujeto ($PPR \sim \text{Grupo} + (1|\text{Sujeto})$). La PPR fue función del grupo ($\chi^2(1) = 8.45, p < .004$). La PPR fue 3.26 ± 1.04 s (Pendiente + EEM) mayor para el grupo A que para el grupo B ($t = -3.122, p < .01$).”

*El script resultante puede descargarse de:

https://github.com/GELopezTolsa/TallerMLM/blob/main/Script_15.R

*Nota: los datos y modelos están adaptados para facilitar el desarrollo del taller y no representan un análisis final de los mismos.

Modelo con diseño de seis grupos

Paso 1: Preparar los datos.

- Nuevamente verificamos que nuestros datos estén en formato “long”, e identificamos nuestras variables de interés.
- En este caso tendremos como VD a la PPR de nuevo, y como VIs al Grupo (A vs. B) y valor del intervalo fijo (IF). Observemos que ambas están señaladas por letras.
- Como posibles efectos aleatorios tenemos sujetos y sesiones.

	A	B	C	D	E
IF		Sesion	Grupo	PPR	Sujeto
E		1	A	38.0491802	101
E		1	A	23.6754098	103
E		1	A	20.057377	105
E		1	A	22.2754099	107
E		1	A	31.904918	109
E		1	A	21.7114753	1011
E		1	A	28.4262296	1013

Paso 2: Preparar el script.

1. Crear un nuevo Script R (es el primer tipo de archivo).

2. Inicio del Script:

El inicio del script será muy similar al ejemplo anterior, incluiremos:

- Línea para borrar el ambiente.
- Activación de paqueterías.
- Directorio.
- Objeto de R en el que se guarden nuestros datos. Nótese que utilizamos el nombre “datos2” para no crear confusiones al tener dos objetos de datos.

El inicio del script se vería así:

```
Script_15.R* x Script_total.R* x
← → ↻ 🔍 📄 Source on Save
1 m(list=ls()) #sirve para borrar el ambiente
2
3 #llamamos las 3 librerías/paquetes que descargamos anteriormente
4 library(psych)
5 library(lme4)
6 library(lmerTest)
7
8 #Especificamos el directorio con el que vamos a estar trabajando (se puede hacer
9 #desde el menú session o poniéndola entre paréntesis con el comando setwd())
10
11 setwd("~/Dropbox/aNew Statistics/Tutorial BLMM para AEC/Taller")
12
13 #Creamos una nueva variable para nuestros datos.
14
15 datos2 <- read.csv("Data_Total.csv")
16
```

Corremos esta parte del código y verificamos que el objeto se haya cargado adecuadamente.

3. Construcción de modelos.

a. Construimos el modelo nulo.

El modelo nulo será igual que en el ejemplo anterior, incluyendo la VD e interceptos aleatorios por sujeto. Hay que verificar que pongamos el nombre correcto del objeto de datos.

```
21  
22 mo0 = lmer(PPR ~ (1|Sujeto),  
23           data = datos2)  
24  
25 summary(mo0)  
26
```

- En este ejemplo llamaremos a los modelos como “moX” en lugar de “mX”, sólo para evitar confusiones.
- Incluimos la función *summary()* de nuevo.

b. Ejecutamos el código hasta aquí y verificamos nuestros resultados:

```
Console Terminal x Markers x Jobs x  
~/Dropbox/aNew Statistics/Tutorial BLMM para AEC/Taller/ ↗  
> mo0 = lmer(PPR ~ (1|Sujeto),  
+           data = datos2)  
> summary(mo0)  
Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']  
Formula: PPR ~ (1 | Sujeto)  
Data: datos2  
  
REML criterion at convergence: 1161.4  
  
Scaled residuals:  
    Min       1Q   Median       3Q      Max  
-5.9499 -0.3718 -0.0331  0.3262  5.5469  
  
Random effects:  
Groups   Name      Variance Std.Dev.  
Sujeto   (Intercept) 88.806   9.424  
Residual              4.689   2.165  
Number of obs: 220, groups: Sujeto, 44  
  
Fixed effects:  
              Estimate Std. Error    df t value Pr(>|t|)  
(Intercept)   17.957      1.428  43.000   12.57 5.35e-16 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
> |
```

Una vez más, dado que sólo incluimos efectos aleatorios por sujeto el intercepto debe ser similar al promedio de nuestros datos:

H1 fx =PROMEDIO(D2:D221)									
	A	B	C	D	E	F	G	H	I
1	IF	Sesion	Grupo	PPR	Sujeto		Promedio	17.9573621	
2	E		1 A	38.0491802	101				
3	E		1 A	23.6754098	103				

c. Ahora creamos un modelo un poco más complejo, en el que incluiremos nuestra VI principal (Grupo) y nuestro efecto aleatorio (sujetos, 1|Sujeto):

```
30 mo1 = lmer(PPR ~ Grupo + (1|Sujeto),
31           data = datos2)
32
33 summary(mo1)
```

d. De nuevo, una vez que corrimos el modelo, vamos a verificar los datos:

```
Console Terminal x Markers x Jobs x
~/Dropbox/aNew Statistics/Tutorial BLMM para AEC/Taller/ ↗
> datos2 <- read.csv("Data_Total.csv")
> mo1 = lmer(PPR ~ Grupo + (1|Sujeto),
+           data = datos2)
> summary(mo1)
Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
Formula: PPR ~ Grupo + (1 | Sujeto)
Data: datos2

REML criterion at convergence: 1156.7

Scaled residuals:
    Min       1Q   Median       3Q      Max
-5.9444 -0.3727 -0.0378  0.3313  5.5524

Random effects:
Groups   Name      Variance Std.Dev.
Sujeto   (Intercept) 89.360   9.453
Residual              4.689   2.165
Number of obs: 220, groups: Sujeto, 44

Fixed effects:
              Estimate Std. Error    df t value Pr(>|t|)
(Intercept)   19.187      2.026  42.000   9.470 5.55e-12 ***
GrupoB        -2.459      2.865  42.000  -0.858   0.396
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Correlation of Fixed Effects:
      (Intr)
GrupoB -0.707
> |
```

Podemos observar que el intercepto y la pendiente son bastante similares a los datos:

Con		A	B	C	D	E	F	G	H	I
1	IF	Sesion	Grupo	PPR	Sujeto			Promedio	17.9573621	
2	E		1 B	38.0491802	101					
3	E		1 B	23.6754098	103			Grupo A	19.186617	
4	E		1 B	20.057377	105			Grupo B	16.7281073	
5	E		1 B	22.2754099	107			A - B	2.45850971	
6	E		1 B	31.904918	109					

Y que nuevamente el grupo A tiene una PPR mayor que el grupo B, por lo que la pendiente es negativa.

e. En este caso tenemos otra variable de interés, que es el IF, por lo que haremos un modelo que también lo incluya:

```

37
38 mo2 = lmer(PPR ~ IF + Grupo + (1|Sujeto),
39           data = datos2)
40
41 summary(mo2)
42

```

- Observemos que ahora los efectos fijos tienen más datos, ya que se incluyen las pendientes de cada IF.

En este caso, el intercepto corresponde al grupo A y el IF “C”; y nuestras pendientes van a mostrar la diferencia entre nuestro intercepto y los otros dos valores de IF; y después la diferencia con el grupo B.

```

Fixed effects:
              Estimate Std. Error    df t value Pr(>|t|)
(Intercept)   10.410      1.310 40.000   7.947 9.32e-10 ***
IFD            6.718      1.713 40.000   3.921 0.000337 ***
IFE           19.096      1.586 40.000  12.038 7.09e-15 ***
GrupoB        -2.459      1.353 40.000  -1.817 0.076673 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Podemos comprobarlo con nuestros datos también:

Claves IF	Promedio en cada IF
C = 15 s	9.190558212
D = 30 s	15.89907103
E = 60 s	28.27731558
Pendientes	
15s - 30s	-6.70851281
15s - 60s	-19.0867574

- En intercepto va a tomar en cuenta el grupo A y la pendiente “C”.
- Vemos que son bastante similares.
- En este caso las pendientes son positivas, ya que las PPR son mayores a mayor el IF.
- Nuevamente la pendiente para el grupo va a ser negativa, ya que la PPR del grupo A es mayor que la del grupo B.

f. Vamos a crear un cuarto modelo en el que vamos a usar la variable de IF para crear pendientes aleatorias para cada grupo.

```

46 mo3 = lmer(PPR ~ Grupo + (1|Sujeto) + (Grupo|IF),
47           data = datos2)
48
49 summary(mo3)
50

```

Además de usar la función *summary()*, vamos a usar la función *coef()*, con la que podremos ver la pendiente para cada grupo:

```

$IF
  (Intercept)  GrupoB
C    10.95634 -3.319251
D    17.25887 -2.660118
E    28.86271 -1.446562

```

g. Ahora utilizaremos la función `anova()` para hacer la prueba de razón de verosimilitud:

```

> anova(mo0,mo1,mo2,mo3)
refitting model(s) with ML (instead of REML)
Data: datos2
Models:
mo0: PPR ~ (1 | Sujeto)
mo1: PPR ~ Grupo + (1 | Sujeto)
mo2: PPR ~ IF + Grupo + (1 | Sujeto)
mo3: PPR ~ Grupo + (1 | Sujeto) + (Grupo | IF)
      npar    AIC    BIC logLik deviance   Chisq Df Pr(>Chisq)
mo0      3 1170.0 1180.1 -581.98   1164.0
mo1      4 1171.2 1184.8 -581.60   1163.2  0.7647  1    0.3819
mo2      6 1107.0 1127.4 -547.51   1095.0 68.1812  2 1.565e-15 ***
mo3      7 1123.3 1147.0 -554.63   1109.3  0.0000  1    1.0000
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
>

```

Veremos que el mejor modelo es `mo2`, en el que tanto IF como Grupo eran efectos fijos y teníamos interceptos aleatorios por sujeto.

Paso 3: Análisis e interpretación del modelo.

1. Ver el mejor modelo usando la función `summary()`

```

Console Terminal x Markers x Jobs x
~/Dropbox/aNew Statistics/Tutorial BLMM para AEC/Taller/
> summary(mo2)
Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
Formula: PPR ~ IF + Grupo + (1 | Sujeto)
Data: datos2

REML criterion at convergence: 1086.3

Scaled residuals:
    Min       1Q   Median       3Q      Max
-5.9328 -0.3598  0.0030  0.3586  5.5640

Random effects:
 Groups   Name      Variance Std.Dev.
 Sujeto   (Intercept) 19.195   4.381
 Residual              4.689   2.165
Number of obs: 220, groups: Sujeto, 44

Fixed effects:
              Estimate Std. Error    df t value Pr(>|t|)
(Intercept)   10.410      1.310 40.000   7.947 9.32e-10 ***
IFD             6.718      1.713 40.000   3.921 0.000337 ***
IFE            19.096      1.586 40.000  12.038 7.09e-15 ***
GrupoB        -2.459      1.353 40.000  -1.817 0.076673 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Correlation of Fixed Effects:
      (Intr) IFD   IFE
IFD   -0.561
IFE   -0.606  0.463
GrupoB -0.516  0.000  0.000
>

```

Vemos que esta vez las pendientes para los diferentes IFs son significativas, mientras que la pendiente de grupo no lo es. Esto quiere decir que, aunque el modelo lo incluya, el grupo tiene poco peso en la distribución de los datos en comparación con los valores de IF.

Paso 4: Redactar análisis de datos y resultados.

Nuevamente haremos la redacción de la sección de análisis de datos y de resultados, tomando en cuenta los puntos que vimos en el ejemplo anterior.

1. Ejemplo de redacción de sección de análisis de datos:

“El uso de Modelos Lineales de Efectos Mixtos ha ido incrementando en psicología y otras ciencias de la conducta, ya que presenta varias ventajas sobre otros métodos estadísticos, como que toman en cuenta la varianza intra- y entre-sujetos, lidian bien con datos desbalanceados y/o anidados y nos indican la dirección y magnitud del efecto (Boisgontier & Cheval, 2016; Brown, 2021; Harrison et al., 2018; Young, 2018; Winter, 2013). Se utilizaron Modelos Lineales Mixtos para evaluar las diferencias en la pausa post-reforzamiento (PPR) de los grupos A y B en los tres valores de IF. Primero se construyó un modelo nulo, y luego se usó una prueba de razón de verosimilitud para determinar cuál es el modelo que mejor se ajustaba a los datos. El modelo que mejor se ajustaba a los datos será descrito en la sección de resultados. Todos los análisis de efectos mixtos se llevaron a cabo usando los paquetes lme4 (Bates, Mächler, Bolker & Walker, 2015) y lmerTest (Kuznetsova, Brockhoff & Christensen, 2017) en R (R Team, 2012), usando el ambiente Rstudio (Rstudio Team, 2020). Los códigos utilizados y bases de datos se pueden encontrar en github.com/ejemplo/cienciaabierta.”

2. Ejemplo de redacción de sección de resultados.

“El Modelo Lineal Mixto usado en el Experimento 2 incluyó al grupo (A vs. B) y al valor de intervalo fijo (15, 30 y 60 s) como efecto fijo, así como interceptos aleatorios por sujeto (PPR ~ Grupo + IF + (1|Sujeto)). La PPR fue función del grupo y del valor del IF ($\chi^2(2) = 68.18$, $p < .001$). La PPR fue 6.71 ± 1.31 s más corta para el IF 15 s que para el IF 30 s ($t = 3.921$, $p < .001$), y 19.09 ± 1.58 s más corta que para el IF 60 s ($t = 12.038$, $p < .001$). Por otro lado, la PPR fue 2.46 ± 1.36 s más corta para el grupo B que para el grupo A, aunque esta diferencia no fue significativa ($t = -1.82$, $p = .077$).”

*El script resultante puede descargarse de:

https://github.com/GELopezTolsa/TallerMLM/blob/main/Script_total.R

*Nota: los datos y modelos están adaptados para facilitar el desarrollo del taller y no representan un análisis final de los mismos.

Referencias

- Brown, V. A. (2021). An introduction to Linear Mixed-Effects Modeling in R. *Advances in methods and Practices in Psychological Science*, 4(1), 1-19.
- Boisgontier, M. P., Cheval, B. 2016. The anova to mixed model transition. *Neurosci Biobehav Rev.* 68, 1004-1005. <https://doi.org/10.1016/j.neubiorev.2016.05.034>
- Harrison, X. A., Donaldson, L., Correa-Cano, M. E., Evans, J. Fisher, D.N., Goodwin, C.E.D., Robinson, B.S., Hodgson, D.J., Inger, R. 2018. A brief introduction to mixed effects modelling and multi-model inference in ecology. *PeerJ*. E4794. <https://doi.org/10.7717/peerj.4794>
- López-Tolsa, G.E. & Pellón, R. (in press). Assessment of the ‘timing’ function of schedule-induced behavior on fixed-interval performance. *Journal of Experimental Psychology: Animal Learning and Cognition*.
- Sorensen, T., Hohenstein, S., Vasishth, S. 2016. Bayesina linear mixed models using stan: A tutorial for psychologists, linguistics, and cognitive scientists. *The Quantitative Methods for Psychology*. 12. <http://doi.org/10.20982/tqmp.12.3.p175>
- Winter, B. 2013. Linear models and linear mixed effects models in R with linguistic applications. *arXiv.1308.5499*